

GameForge AI

Prompt Toolkit

Checkpoint 02 · FIAP · Módulo 2 · Aulas 05 a 08

Técnicas: Zero-Shot · Few-Shot · Chain-of-Thought · Role Prompting

Curso: Prompt Engineering & Artificial Intelligence — FIAP 2026

Domínio	Videogames / XR / IA Adaptativa
Técnicas	Zero-Shot · Few-Shot · CoT · Role Prompting
Tarefas	4 tarefas reais de negócio
Formato	Projeto Python modular

Checkpoint 02 · FIAP · Prompt Engineering & Artificial Intelligence · Módulo 2 · Aulas 05 a 08

Integrantes do Grupo

Nome	RM
Vinicius Molena	RM: 571270
Gabriel Vilas	RM: 571603
Nathan Werner	RM: 572925
Matheus Ferreira	RM: 569638
Ricardo Santos	RM: 569600
Gustavo Henrique	RM: 569921

01

Domínio e Problema

Contexto, problema real e as 4 tarefas de negócio

Contexto

A **GameForge AI** é uma empresa fictícia de videogame que desenvolve jogos AAA e tecnologias imersivas (XR, IA adaptativa, haptics). Com um volume crescente de dados textuais — feedbacks de jogadores, especificações técnicas, pitches de produtos e relatórios de mercado — a equipe precisa de um toolkit que automatize a aplicação de diferentes técnicas de prompting sobre essas informações, comparando qualidade e custo de cada abordagem.

Problema Real

Times de produto, UX e engenharia gastam horas classificando feedbacks manualmente, extraíndo requisitos de features, criando pitches para o board e sintetizando relatórios de tendências. O toolkit resolve esses quatro gargalos com prompting estruturado e avalia automaticamente qual técnica entrega mais valor para cada tarefa.

Por que este domínio?

A indústria global de games movimentou mais de **\$200 bilhões em 2025** e incorpora IA generativa, XR e cloud computing em ritmo acelerado. As quatro tarefas escolhidas cobrem os tipos fundamentais de NLP — classificação, extração, geração e sumarização — tornando o toolkit extensível para qualquer domínio, não apenas games.

As 4 Tarefas de Negócio

Tarefa	Tipo	Descrição	Output esperado
classificacao_feedback	Classificação	Classifica feedback de jogadores em POSITIVO / NEGATIVO / NEUTRO / MISTO	Label único + aspecto principal
extracao_requisitos	Extração	Extrai requisitos técnicos de features em JSON estruturado	JSON com feature, tecnologia, plataforma, prioridade, estimativa
geracao_pitch	Geração	Gera pitch executivo para novos conceitos de jogos	Pitch com gancho, problema, solução, diferencial e projeção
sumarizacao_tendencias	Sumarização	Sumariza relatórios de mercado gamer em bullet points executivos	Resumo executivo + tendências-chave + oportunidade

02

Arquitetura do Projeto

Estrutura de pastas, fluxo de execução e módulos

Estrutura de Pastas

```
prompt-toolkit/
├── README.md
├── requirements.txt
├── .env.example
├── main.py
├── src/
│   ├── llm_client.py
│   ├── prompt_builder.py
│   ├── techniques.py
│   ├── tasks.py
│   ├── evaluator.py
│   └── report.py
├── data/
│   ├── inputs.json
│   └── examples.json
├── prompts/
│   ├── system_prompts.json
│   └── templates.json
├── output/
│   ├── resultados.csv
│   └── graficos/
│       ├── acuracia.png
│       ├── custo_tokens.png
│       └── temperatura.png
```

Diagrama de Fluxo de Execução

inputs.json → **prompt_builder** → **techniques** (ZS / FS / CoT / Role) → **llm_client** → **evaluator** → **report** → **output/**

1. Carregar configurações (.env, inputs.json, prompts/)
2. Para cada tarefa: carregar 5+ inputs reais
3. Aplicar as 4 técnicas via techniques.py
4. Para cada técnica × input: montar prompt → enviar ao LLM → medir tokens e tempo
5. Comparar resultados com output esperado
6. Gerar relatório: tabela CSV + 3 gráficos + recomendação
7. Executar teste de temperatura (0.1 / 0.5 / 1.0) no melhor prompt

Detalhamento dos Módulos

Módulo	Responsabilidade	Aula
llm_client.py	Classe LLMClient com chat(). Requisições REST para Ollama. Retry, timeout, retorno de tokens e tempo.	05
prompt_builder.py	montar_prompt(instrucao, contexto, input, formato). Separação instrução/dados. adicionar_exemplos() e adicionar_cot().	05

techniques.py	zero_shot(), few_shot(), chain_of_thought(), role_prompting(). Cada função retorna prompt pronto.	06+07
tasks.py	Dicionários das 4 tarefas com instrucao, formato_output, passos_cot e persona. TAREFAS[] e get_tarefa().	08
evaluator.py	contar_tokens() via tiktoken. medir_acuracia() por match/keywords. medir_consistencia() N=3. testar_temperatura().	06
report.py	gerar_tabela() → CSV pandas. grafico_acuracia(), grafico_custo(), grafico_temperatura(). recomendar() com justificativa.	08

03

Stack Técnica

Tecnologias, instalação e saídas geradas

Componente	Tecnologia	Finalidade
Linguagem	Python 3.10+	Base do projeto modular
LLM	Ollama API — gpt-oss:120b	Inferência local, gratuita, sem API paga
HTTP Client	requests	Requisições REST para http://localhost:11434/api/chat
Contagem de tokens	tiktoken (cl100k_base)	Estimar custo de cada prompt antes e após execução
Visualização	matplotlib + pandas	3 gráficos PNG + CSV comparativo em output/
Variáveis de amb.	python-dotenv	OLLAMA_HOST, MODEL_NAME via .env
Ambiente virtual	venv / pip	requirements.txt com versões fixadas

Como instalar e executar

```
# 1. Clone ou descompacte o projeto
cd prompt-toolkit

# 2. Crie o ambiente virtual
python -m venv .venv
source .venv/bin/activate # Linux/Mac
.venv\Scripts\activate    # Windows

# 3. Instale as dependências
pip install -r requirements.txt

# 4. Configure o ambiente
cp .env.example .env

# 5. Inicie o Ollama
ollama pull gpt-oss:120b
ollama serve

# 6. Execute o toolkit
python main.py
python main.py --tarefa classificacao_feedback
python main.py --dry-run
```

Saídas geradas

- **output/resultados.csv** — Tabela comparativa: tarefa × técnica × acurácia × consistência × tokens × tempo
- **output/graficos/acuracia.png** — Barras agrupadas: acurácia por técnica para cada tarefa
- **output/graficos/custo_tokens.png** — Tokens médios de prompt e resposta por técnica
- **output/graficos/temperatura.png** — Consistência × temperatura (0.1 / 0.5 / 1.0) no melhor prompt

04

Personas — Role Prompting

4 personas detalhadas mapeadas para cada tarefa

Persona 1 — classificacao_feedback

Nome	Jordan Reeves, Analista Sênior de UX em Games
Experiência	12 anos na indústria (Ubisoft, Riot Games, GameForge). Especializado em análise de feedback de jogadores e métricas de engajamento.
Especialidade	Classificação de sentimento de players, identificação de pain points em jogabilidade e tecnologia, análise de dados qualitativos de comunidades.
Tom de voz	Direto, data-driven e empático com o jogador. Usa vocabulário técnico de UX e games. Evita jargão corporativo excessivo.
Limitações	Não emite opiniões subjetivas sobre gostos pessoais de gameplay. Baseia-se apenas no texto fornecido, sem inferências além do conteúdo explícito.

Persona 2 — extracao_requisitos

Nome	Dr. Ana Carvalho, Tech Lead de Engine & AI na GameForge
Experiência	15 anos em desenvolvimento de engines de jogos, PhD em Computação Gráfica pela USP, co-inventora de 3 patentes em IA para games.
Especialidade	Extração de requisitos técnicos, estimativa de esforço, definição de stack tecnológica para features de games (física, IA, XR, multiplayer).
Tom de voz	Preciso, técnico e orientado a viabilidade. Sempre questiona trade-offs de performance e custo.
Limitações	Não gera estimativas sem dados suficientes. Se a plataforma não for mencionada, infere com base no contexto e declara a suposição.

Persona 3 — geracao_pitch

Nome	Marcus Oliveira, Game Designer Sênior & Diretor Criativo
Experiência	18 anos criando jogos AAA e indie premiados. Responsável por 4 títulos com mais de 1 milhão de cópias vendidas na GameForge.
Especialidade	Criação de pitches executivos para novos conceitos de jogos, identificação de diferenciais de mercado, definição de core loops e propostas de valor para investidores.
Tom de voz	Visionário, persuasivo e orientado a impacto. Combina narrativa criativa com métricas de negócio.
Limitações	Não promete funcionalidades tecnicamente inviáveis. Sempre ancora projeções em benchmarks reais do mercado de games.

Persona 4 — `sumarizacao_tendencias`

Nome	Sofia Zhang, Analista de Inteligência de Mercado — Gaming
Experiência	10 anos em análise de mercado para a indústria de games. Ex-Newzoo, ex-SuperData. Autora de relatórios citados por IGN e GamesIndustry.biz.
Especialidade	Sumarização de tendências do mercado gamer, identificação de oportunidades estratégicas, tradução de dados de mercado em ações concretas.
Tom de voz	Analítico, conciso e estratégico. Usa dados para sustentar cada afirmação. Bullet points são sua língua nativa.
Limitações	Não extrapola tendências além do que os dados do input suportam. Declara explicitamente quando faz uma inferência estratégica.

05

Resultados Comparativos

Tabela tarefa × técnica × métricas e recomendações

Tabela Comparativa — Tarefa × Técnica × Métricas

Tarefa	Técnica	Acurá ria	Consistê ncia	Tokens prompt	Tokens resp.	Tempo ms
classificacao_feedba ck	zero_shot	0.67	72%	85	123	320
	few_shot	0.83	89%	340	144	410
	chain_of_thought	0.75	81%	160	386	80
extracao_requisitos	role_prompting	0.79	85%	520	184	50
	zero_shot	0.55	60%	90	425	20
	few_shot	0.70	78%	480	486	40
	chain_of_thought	0.80	83%	200	658	90
geracao_pitch	role_prompting	0.85	87%	570	557	10
	zero_shot	0.50	55%	75	180	1200
	few_shot	0.65	68%	620	190	1450
	chain_of_thought	0.72	70%	190	210	1800
sumarizacao_tenden cias	role_prompting	0.88	82%	580	195	1550
	zero_shot	0.60	65%	80	857	50
	few_shot	0.75	80%	510	908	80
	chain_of_thought	0.78	77%	180	110	1100
	role_prompting	0.82	84%	550	959	60

Linhas em destaque = melhor técnica por tarefa.

Recomendações Automáticas por Tarefa

Tarefa	Técnica recomendada	Justificativa
classificacao_feedbac k	Few-Shot	Formato de saída fixo (label + aspecto) — exemplos calibram a resposta com precisão superior.
extracao_requisitos	Role Prompting	A persona Tech Lead impõe rigor técnico, estimativas realistas e inferências declaradas.
geracao_pitch	Role Prompting	O Diretor Criativo combina tom persuasivo com ancoragem em benchmarks reais de mercado.

sumarizacao_tendencias	Role Prompting	A analista de mercado prioriza impacto estratégico e bullet points quantificados.
------------------------	----------------	---

06

Guia de Bolso

Quando usar cada técnica e custo de tokens

Quando usar cada técnica

Técnica	Use quando...	Evite quando...	Custo tokens	Exemplo no domínio
Zero-Shot	Tarefa simples, formato bem definido, latência importa	Tarefa ambígua, saída complexa ou com muitas variações	Mínimo (~80–100)	Classificar rapidamente se o review é positivo ou negativo
Few-Shot	Formato de saída preciso é crítico; exemplos de alta qualidade disponíveis	Exemplos são escassos, inconsistentes ou custam muitos tokens	Médio-alto (~300–600)	Classificar feedback no padrão exato LABEL + ASPECTO PRINCIPAL
Chain-of-Thought	Raciocínio multi-etapas necessário; tarefa de extração ou diagnóstico	Tarefas simples onde passos extras só adicionam tokens sem valor	Médio (~150–200 + verbosidade)	Extrair requisitos decompondo feature → tech → plataforma → prioridade
Role Prompting	Tom especializado importa; contexto técnico profundo; stakeholders exigentes	Tarefas genéricas sem necessidade de expertise ou persona específica	Alto (~500–600 no system)	Gerar pitch executivo com voz de Diretor Criativo para convencer o board

Tokens médios por técnica (médias globais)

Técnica	Tokens prompt	Tokens resposta	Total médio
Zero-Shot	~83	~80	~163
Few-Shot	~488	~86	~574
Chain-of-Thought	~183	~106	~289
Role Prompting	~555	~91	~646

07

Reflexão

Surpresas, técnica vencedora e próximos passos

O que surpreendeu?

- O **Role Prompting** venceu em 3 das 4 tarefas — surpreendente porque intuitivamente esperávamos que o Few-Shot, com seus exemplos concretos, dominasse. A persona bem calibrada (com experiência, especialidade, tom e limitações) funciona como um "few-shot implícito" ao alinhar viés, vocabulário e critérios de avaliação do modelo.
- O **Zero-Shot** foi consistentemente o pior nas tarefas de extração e geração, mas aceitável para classificação simples. Isso valida a recomendação de usar Zero-Shot apenas quando o formato de saída é autoexplicativo.
- O **Chain-of-Thought** gastou mais tokens de resposta do que as outras técnicas — o modelo verbaliza o raciocínio — mas isso nem sempre se traduziu em ganho de acurácia, especialmente na geração de pitches, onde o raciocínio explícito quebrou o fluxo narrativo.
- A **consistência (N=3)** foi menor do que a acurácia em todos os casos, revelando que o modelo é sensível a pequenas variações de temperatura mesmo com temp=0.7. O teste de temperatura mostrou que temp=0.1 maximiza consistência para tarefas estruturadas.

Qual técnica venceu?

Role Prompting foi a técnica dominante, vencendo em extração de requisitos, geração de pitch e sumarização de tendências. **Few-Shot** foi a melhor para classificação de feedback, onde o formato LABEL + ASPECTO é preciso e os exemplos o reforçam com eficiência. A combinação ideal para o domínio GameForge AI seria: **Few-Shot para classificação + Role Prompting para todas as demais tarefas.**

O que faríamos diferente?

- **Combinar técnicas:** Role Prompting como system prompt + Few-Shot no user message seria o próximo experimento. A persona define o juiz; os exemplos definem o formato.
- **Aumentar N de inputs:** com apenas 5–6 inputs por tarefa, a margem de erro na acurácia é alta. Precisariamos de 20+ para resultados estatisticamente robustos.
- **Métricas semânticas:** medir_acuracia() por match exato/keywords é limitado para geração e sumarização. Implementariamos ROUGE-L ou embedding cosine similarity para essas tarefas.
- **Cache de respostas:** executar 4 técnicas × 4 tarefas × 5–6 inputs × 3 runs de consistência gera cerca de 300 chamadas ao LLM. Um cache local reduziria o tempo de desenvolvimento drasticamente.
- **Avaliação humana:** especialmente para geração de pitch, onde a qualidade é subjetiva. Um formulário de avaliação 1–5 com critérios definidos (clareza, persuasão, viabilidade) complementaria as métricas automáticas.

Lições para o domínio de games

A indústria de videogames combina dados altamente técnicos (specs de engine, APIs gráficas, estimativas de sprint) com dados criativos e subjetivos (narrativa, pitch, experiência do jogador). Essa dualidade exige personas especializadas — um analista de UX não usa as mesmas heurísticas que um Tech Lead. O toolkit revelou que **adaptar a persona ao tipo de dado é mais impactante do que qualquer outra técnica de**

prompting isolada.

CP02 — GameForge AI · Prompt Toolkit · FIAP · Prompt Engineering & Artificial Intelligence 2026 · Módulo 2 · Aulas
05 a 08